

Лекция 5: Классификация

Машин Иван Сергеевич

январь 2026

Постановка задачи классификации

- Пусть X – множество наблюдаемых признаков;
- Y – конечное множество меток классов;

Постановка задачи классификации

- Пусть X – множество наблюдаемых признаков;
- Y – конечное множество меток классов;
- Существует функция $y: X \rightarrow Y$;
- Значения функции y известны на конечной выборке
$$X^n = \{(x_1, y_1), \dots, (x_n, y_n)\};$$

Постановка задачи классификации

- Пусть X – множество наблюдаемых признаков;
- Y – конечное множество меток классов;
- Существует функция $y: X \rightarrow Y$;
- Значения функции y известны на конечной выборке
$$X^n = \{(x_1, y_1), \dots, (x_n, y_n)\};$$
- Требуется построить алгоритм $a: X \rightarrow Y$, способный классифицировать произвольный объект $x \in X$.

Постановка задачи классификации

- Пусть X – множество наблюдаемых признаков;
- Y – конечное множество меток классов;

Постановка задачи классификации

- Пусть X – множество наблюдаемых признаков;
- Y – конечное множество меток классов;
- Множество $X \times Y$ является вероятностным пространством с плотностью распределения $p(x, y) = P(y)p(x|y)$;

Постановка задачи классификации

- Пусть X – множество наблюдаемых признаков;
- Y – конечное множество меток классов;
- Множество $X \times Y$ является вероятностным пространством с плотностью распределения $p(x, y) = P(y)p(x|y)$;
- Вероятности появления объектов каждого из классов $P_y = P(y)$ называются *априорными вероятностями* классов;

Постановка задачи классификации

- Пусть X – множество наблюдаемых признаков;
- Y – конечное множество меток классов;
- Множество $X \times Y$ является вероятностным пространством с плотностью распределения $p(x, y) = P(y)p(x|y)$;
- Вероятности появления объектов каждого из классов $P_y = P(y)$ называются *априорными вероятностями* классов;
- Плотности распределения $p_y(x) = p(x|y)$ называются функциями правдоподобия классов;

Постановка задачи классификации

Задача:

- Имеется выборка $X^n = \{(x_1, y_1), \dots, (x_n, y_n)\}$ из неизвестного распределения $p(x, y) = P_y p_y(x)$. Требуется построить эмпирические оценки априорных вероятностей $\hat{P}_y$ и функций правдоподобия $\hat{p}_y(x)$ для каждого из классов $y \in Y$;
- Используя функции правдоподобия и априорные вероятности классов построить алгоритм $a(x)$, способный классифицировать произвольный объект $x \in X$.

- $d(x_i, x_j)$ – функция расстояния на множестве X ;

- $d(x_i, x_j)$ – функция расстояния на множестве X ;
- $\forall u \in X^p$ положим: $d(u, x_1) \leq d(u, x_2) \leq \dots \leq d(u, x_u)$;

- $d(x_i, x_j)$ – функция расстояния на множестве X ;
- $\forall u \in X^p$ положим: $d(u, x_1) \leq d(u, x_2) \leq \dots \leq d(u, x_u)$;
- $w(i, u)$ – функция весов, оценивающая степень важности i – го соседа для классификации объекта u ;

- $d(x_i, x_j)$ – функция расстояния на множестве X ;
- $\forall u \in X^p$ положим: $d(u, x_1) \leq d(u, x_2) \leq \dots \leq d(u, x_u)$;
- $w(i, u)$ – функция весов, оценивающая степень важности i – го соседа для классификации объекта u ;

Тогда $a(u) = \arg \max_{y \in Y} \sum_i [y(x_{i,u}) = y] w(i, u)$

- $w(i, x) = [i \leq k], k = \text{const}$ - KNN classifier;

- $w(i, x) = [i \leq k], k = \text{const}$ - KNN classifier;
- $w(i, x) = [i \leq k]v_i, k = \text{const}$ - WKNN classifier;

- $w(i, x) = [i \leq k], k = \text{const}$ - KNN classifier;
- $w(i, x) = [i \leq k]v_i, k = \text{const}$ - WKNN classifier;
 - $v_i = \frac{k+1-i}{k}$ - линейно-убывающие веса;

- $w(i, x) = [i \leq k], k = \text{const}$ - KNN classifier;
- $w(i, x) = [i \leq k]v_i, k = \text{const}$ - WKNN classifier;
 - $v_i = \frac{k+1-i}{k}$ - линейно-убывающие веса;
 - $v_i = q^i, 0 < q < 1$ - экспоненциально-убывающие веса;

- $w(i, x) = [i \leq k], k = \text{const}$ - KNN classifier;
- $w(i, x) = [i \leq k]v_i, k = \text{const}$ - WKNN classifier;
 - $v_i = \frac{k+1-i}{k}$ - линейно-убывающие веса;
 - $v_i = q^i, 0 < q < 1$ - экспоненциально-убывающие веса;
- $w(i, x) = K(r), K(r)$ – ядро, $K(r) = K(d(u, x_i))$

Плюсы:

- Простой алгоритм
- Интерпретируемость

Минусы:

- Подбор гиперпараметров, выбор метрики, нормирование
- Выбросы
- Размер выборки, curse of dimensionality: $CV(D) = \frac{\sigma}{\mu} \rightarrow 0, p \rightarrow \infty$, т.е. все объекты примерно одинаково далеки друг от друга

Линейные методы классификации

Линейные методы классификации = линейные **разделяющие границы**

- Пусть имеем K классов: $1, \dots, K$;
- Разделяющая граница между классами k и l – набор точек, для которых

$$\hat{f}_k(x) = \hat{f}_l(x), \text{ или множество } \left\{ x: (\hat{b}_{k0} - \hat{b}_{l0}) + (\hat{b}_k - \hat{b}_l)^T x = 0 \right\} - \text{т.е.}$$

гиперплоскость или аффинное множество в пространстве признаков x , где

$(\hat{b}_k - \hat{b}_l)^T$ - вектор нормали к гиперплоскости, а $(\hat{b}_{k0} - \hat{b}_{l0})$ - bias

(свободный член), определяющий сдвиг гиперплоскости относительно начала координат.

Линейные методы классификации

Линейная регрессия

$$y(x) = w^T x + b$$

Линейные методы классификации

Линейная регрессия

$$y(x) = w^T x + b$$

$$a(x) = \begin{cases} 1, & y(x) \geq \tau \\ 0, & y(x) < \tau \end{cases}$$

Линейные методы классификации

Линейная регрессия

$$y(x) = w^T x + b$$

$$a(x) = \begin{cases} 1, & y(x) \geq \tau \\ 0, & y(x) < \tau \end{cases}$$

$$a(x) = \text{sign}(y(x))$$

Линейные методы классификации

Линейная регрессия


$$y(x) = w^T x + b$$

$$a(x) = \begin{cases} 1, & y(x) \geq \tau \\ 0, & y(x) < \tau \end{cases}$$


$$a(x) = \text{sign}(y(x))$$

- Функция потерь не штрафует за неверные предсказания на границе принятия решений;
- Чувствительна к выбросам;
- Оптимизирует не разделение классов 0 и 1, а пытается провести прямую через 0 и 1.

Линейные методы классификации



Линейные методы классификации



«Наивный» байесовский классификатор

Формула Байеса:

- $P(y|x) = \frac{P(x,y)}{P(x)} = \frac{P(x|y) P(y)}{P(x)}$ - апостериорная вероятность класса y при x ;

«Наивный» байесовский классификатор

Формула Байеса:

- $P(y|x) = \frac{P(x,y)}{P(x)} = \frac{P(x|y) P(y)}{P(x)}$ - апостериорная вероятность класса y при x ;

Функция среднего риска:

- Пусть λ_{ys} - величина потери при отнесении класса y к классу s :

$$\lambda_{yy} = 0; \lambda_{ys} > 0, y \neq s;$$

«Наивный» байесовский классификатор

Формула Байеса:

- $P(y|x) = \frac{P(x,y)}{P(x)} = \frac{P(x|y) P(y)}{P(x)}$ - апостериорная вероятность класса y при x ;

Функция среднего риска:

- Пусть λ_{ys} - величина потери при отнесении класса y к классу s :

$$\lambda_{yy} = 0; \lambda_{ys} > 0, y \neq s;$$

- $A_s = \{x \in X | a(x) = s\}, s \in Y$ – области всех значений x : $a(x)$ равен s .

«Наивный» байесовский классификатор

Формула Байеса:

- $P(y|x) = \frac{P(x,y)}{P(x)} = \frac{P(x|y) P(y)}{P(x)}$ - апостериорная вероятность класса y при x ;

Функция среднего риска:

- Пусть λ_{ys} - величина потери при отнесении класса y к классу s :

$$\lambda_{yy} = 0; \lambda_{ys} > 0, y \neq s;$$

- $A_s = \{x \in X | a(x) = s\}, s \in Y$ – области всех значений x : $a(x)$ равен s .
- Тогда $R(a) = E(\lambda_{ys}) = \sum_y \sum_s \lambda_{ys} P_y P(A_s|y);$

«Наивный» байесовский классификатор

Формула Байеса:

- $P(y|x) = \frac{P(x,y)}{P(x)} = \frac{P(x|y) P(y)}{P(x)}$ - апостериорная вероятность класса y при x ;

Функция среднего риска:

- Пусть λ_{ys} - величина потери при отнесении класса y к классу s :
 $\lambda_{yy} = 0; \lambda_{ys} > 0, y \neq s$;
- $A_s = \{x \in X | a(x) = s\}, s \in Y$ – области всех значений x : $a(x)$ равен s .
- Тогда $R(a) = E(\lambda_{ys}) = \sum_y \sum_s \lambda_{ys} P_y P(A_s|y)$;
- При $\lambda_{ys} = \text{const} (y \neq s)$, $R(a)$ равен вероятности ошибки $a(x)$.

«Наивный» байесовский классификатор

Формула Байеса:

- $P(y|x) = \frac{P(x|y) P(y)}{P(x)};$

Функция среднего риска:

- $R(a) = \sum_y \sum_s \lambda_{ys} P_y P(A_s|y);$

$$R(x) = \sum_y \lambda_y P(y|x)$$

«Наивный» байесовский классификатор

Формула Байеса:

- $P(y|x) = \frac{P(x|y) P(y)}{P(x)};$

Функция среднего риска:

- $R(a) = \sum_y \sum_s \lambda_{ys} P_y P(A_s|y);$

$$R(x) = \sum_y \lambda_y P(y|x)$$

Теорема (*Байесовское решающее правило*):

Если известны $P(y)$ и $P(x|y)$; $\lambda_{yy} = 0$, $\lambda_{ys} = \lambda_y = \text{const}$, то минимум $R(a)$

достигается алгоритмом $a(x) = \arg \max_{y \in Y} \lambda_y P(y|x)$.

При $\lambda_y = 1$ задача стоит в максимизации апостериорной вероятности.

«Наивный» байесовский классификатор

Оценка априорных вероятностей

- Пусть $X_y^l = \{(x_i, y_i)_{i=1}^l \mid y_i = y\}$;

«Наивный» байесовский классификатор

Оценка априорных вероятностей

- Пусть $X_y^l = \{(x_i, y_i)_{i=1}^l \mid y_i = y\}$;
- $\hat{P}(y) \rightarrow \frac{l_y}{l}, l = |X_y^l|, y \in Y$; по ЗБЧ $\hat{P}(y) \xrightarrow{P} P(y)$.

«Наивный» байесовский классификатор

Оценка априорных вероятностей

- Пусть $X_y^l = \{(x_i, y_i)_{i=1}^l \mid y_i = y\}$;
- $\hat{P}(y) = \frac{l_y}{l}, l_y = |X_y^l|, y \in Y$; по ЗБЧ $\hat{P}(y) \xrightarrow{P} P(y)$.

$P(x)$ не имеет смысла оценивать, т.к. он сокращается в формуле классификатора:

$$a(x) = \arg \max_{y \in Y} P(y|x)$$

«Наивный» байесовский классификатор

Предположение о наивности:

- $P(x_j | y, x_1, \dots, x_{j-1}, x_{j+1}, \dots, x_p) = P(x_j | y)$: признаки – независимые случайные величины.

«Наивный» байесовский классификатор

Предположение о наивности:

- $P(x_j|y, x_1, \dots, x_{j-1}, x_{j+1}, \dots, x_p) = P(x_j|y)$: признаки – независимые случайные величины.

Тогда:

- $P(y, x_1, \dots, x_p) = P(y) \prod_{j=1}^p p(x_j|y)$
- а плотности $p(X|y) = p(x_1|y) * p(x_2|y) * \dots * p(x_p|y)$

«Наивный» байесовский классификатор

Предположение о наивности:

- $P(x_j|y, x_1, \dots, x_{j-1}, x_{j+1}, \dots, x_p) = P(x_j|y)$: признаки – независимые случайные величины.

Тогда:

- $P(y, x_1, \dots, x_p) = P(y) \prod_{j=1}^p p(x_j|y)$
- а плотности $p(X|y) = p(x_1|y) * p(x_2|y) * \dots * p(x_p|y)$
- $P(y|X) = \frac{P(y) \prod_{j=1}^p p(x_j|y)}{P(X)} \Rightarrow$ необходимо оценить n одномерных плотностей, а не одну n -мерную, что значительно проще.

«Наивный» байесовский классификатор

Способы оценивания функции правдоподобия

- Gaussian naïve bayes: $P(x_i|y) = \frac{1}{\sqrt{2\pi\sigma_y^2}} \exp\left(-\frac{(x_i-\mu_y)^2}{2\sigma_y^2}\right)$

«Наивный» байесовский классификатор

Способы оценивания функции правдоподобия

- Gaussian naïve bayes: $P(x_i|y) = \frac{1}{\sqrt{2\pi\sigma_y^2}} \exp\left(-\frac{(x_i-\mu_y)^2}{2\sigma_y^2}\right)$
- Multinomial naïve bayes: $P(x_i|y) = \frac{N_{yi}+\alpha}{N_y+\alpha n}$, α — параметр сглаживания

Лапласа, $N_{yi} = \sum_x x_i$ — число раз x_i встречается в наблюдениях класса y ,

$N_y = \sum_i N_{yi}$ — общее количество всех признаков в классе y .

«Наивный» байесовский классификатор

Способы оценивания функции правдоподобия

- Gaussian naïve bayes: $P(x_i|y) = \frac{1}{\sqrt{2\pi\sigma_y^2}} \exp\left(-\frac{(x_i-\mu_y)^2}{2\sigma_y^2}\right)$
- Multinomial naïve bayes: $P(x_i|y) = \frac{N_{yi}+\alpha}{N_y+\alpha n}$, α — параметр сглаживания

Лапласа, $N_{yi} = \sum_x x_i$ — число раз x_i встречается в наблюдениях класса y ,

$N_y = \sum_i N_{yi}$ — общее количество всех признаков в классе y .

- Bernoulli naïve bayes: $P(x_i|y) = P(x_i = 1|y)x_i + (1 - P(x_i = 1|y))(1 - x_i)$

Линейные методы классификации

$$y(x) = w^T x + b = \langle w, x \rangle = z$$

Моделируем вероятность: $P(y|x) = P$:

Линейные методы классификации

$$y(x) = w^T x + b = \langle w, x \rangle = z$$

Моделируем вероятность: $P(y|x) = P$:

(1) $w^T x + b \in \mathbb{R}$, тогда моделирование $P = z$ тоже $\in \mathbb{R}$;

Необходимо найти $\sigma: P = \sigma(z) \in [0,1]$;

Линейные методы классификации

$$y(x) = w^T x + b = \langle w, x \rangle = z$$

Моделируем вероятность: $P(y|x) = P$:

(1) $w^T x + b \in \mathbb{R}$, тогда моделирование $P = z$ тоже $\in \mathbb{R}$;

Необходимо найти $\sigma: P = \sigma(z) \in [0,1]$;

(2) Определим шансы $odds = \frac{P}{1-P} \in [0, \infty]$: при $P = 0.5$, $odds = 0.25 = 1/4$

(читать как «шансы на успех 1 к 4»);

Линейные методы классификации

$$y(x) = w^T x + b = \langle w, x \rangle = z$$

Моделируем вероятность: $P(y|x) = P$:

(1) $w^T x + b \in \mathbb{R}$, тогда моделирование $P = z$ тоже $\in \mathbb{R}$;

Необходимо найти $\sigma: P = \sigma(z) \in [0,1]$;

(2) Определим шансы $odds = \frac{P}{1-P} \in [0, \infty]$: при $P = 0.5$, $odds = 1 = 1/1$

(читать как «шансы на успех 1 к 1»);

(3) Моделировать шансы нельзя, т.к. $z \in [-\infty, +\infty]$, а $odds \in [0, +\infty]$.

Моделируем $\log(odds) \in [-\infty, +\infty]$: $\log(odds) = z$

Линейные методы классификации

$$\log(odds) = z; \quad P(y|x) = \sigma(z)$$

- $\log\left(\frac{P}{1-P}\right) = z$

Линейные методы классификации

$$\log(odds) = z; \quad P(y|x) = \sigma(z)$$

- $\log\left(\frac{P}{1-P}\right) = z$
- $\frac{P}{1-P} = e^z$

Линейные методы классификации

$$\log(odds) = z; \quad P(y|x) = \sigma(z)$$

- $\log\left(\frac{P}{1-P}\right) = z$
- $\frac{P}{1-P} = e^z$
- $P = e^z(1 - P) = e^z - Pe^z$

Линейные методы классификации

$$\log(odds) = z; \quad P(y|x) = \sigma(z)$$

- $\log\left(\frac{P}{1-P}\right) = z$
- $\frac{P}{1-P} = e^z$
- $P = e^z(1 - P) = e^z - Pe^z$
- $P + Pe^z = e^z$

Линейные методы классификации

$$\log(odds) = z; \quad P(y|x) = \sigma(z)$$

- $\log\left(\frac{P}{1-P}\right) = z$
- $\frac{P}{1-P} = e^z$
- $P = e^z(1 - P) = e^z - Pe^z$
- $P + Pe^z = e^z$
- $P(1 + e^z) = e^z$

Линейные методы классификации

$$\log(odds) = z; \quad P(y|x) = \sigma(z)$$

- $\log\left(\frac{P}{1-P}\right) = z$
- $\frac{P}{1-P} = e^z$
- $P = e^z(1 - P) = e^z - Pe^z$
- $P + Pe^z = e^z$
- $P(1 + e^z) = e^z$
- $P = \frac{e^z}{1+e^z} = \frac{1}{\frac{1}{e^z}+1} = \frac{1}{1+e^{-z}}$

Линейные методы классификации

Логистическая регрессия

$$P(y|x) = \frac{1}{1 + e^{-(w^T x + b)}}$$

Обучение:

$$p(y|X, w) = \prod_{i=1} p_i^{y_i} (1 - p_i)^{1-y_i} \rightarrow \max_w$$

Линейные методы классификации

Обучение:

$$p(y|X, w) = \prod_{i=1} p_i^{y_i} (1 - p_i)^{1-y_i} \rightarrow \max_w$$

Линейные методы классификации

Обучение:

$$p(y|X, w) = \prod_{i=1} p_i^{y_i} (1 - p_i)^{1-y_i} \rightarrow \max_w$$

$$L(w, X, y) = - \sum_i (y_i \log(\sigma(z)) + (1 - y_i) \log(\sigma(-z))) \rightarrow \min_w$$

Линейные методы классификации


Обучение:

$$p(y|X, w) = \prod_{i=1} p_i^{y_i} (1 - p_i)^{1-y_i} \rightarrow \max_w$$

$$L(w, X, y) = - \sum_i (y_i \log(\sigma(z)) + (1 - y_i) \log(\sigma(-z))) \rightarrow \min_w$$

$$\nabla_w L(w, X, y) = - \sum_i x_i (y_i - \sigma(z))$$

Линейные методы классификации



Линейные методы классификации

Обучение с регуляризаци:

$$L(w, X, y) = - \sum_i (y_i \log(\sigma(z)) + (1 - y_i) \log(\sigma(-z))) \rightarrow \min_w$$

$$L_{reg} = L + \lambda * \Omega(w),$$

λ – коэффициент регуляризации, Ω – функция регуляризации

$$L2: L_{reg} = L + \lambda ||w||_2^2,$$

Линейные методы классификации

Обучение с регуляризаци:

$$L(w, X, y) = - \sum_i (y_i \log(\sigma(z)) + (1 - y_i) \log(\sigma(-z))) \rightarrow \min_w$$

$$L_{reg} = L + \lambda * \Omega(w),$$

λ – коэффициент регуляризации, Ω – функция регуляризации

$$L2: L_{reg} = L + \lambda ||w||_2^2,$$

$$L1: L_{reg} = L + \lambda ||w||_1,$$

Линейные методы классификации

Обучение с регуляризаци:

$$L(w, X, y) = - \sum_i (y_i \log(\sigma(z)) + (1 - y_i) \log(\sigma(-z))) \rightarrow \min_w$$

$$L_{reg} = L + \lambda * \Omega(w),$$


λ – коэффициент регуляризации, Ω – функция регуляризации

$$L2: L_{reg} = L + \lambda ||w||_2^2,$$

$$L1: L_{reg} = L + \lambda ||w||_1,$$

$$\text{Elastic Net: } L_{reg} = L + \lambda_1 ||w||_1 + \lambda_2 ||w||_2^2.$$

Линейные методы классификации



$$a(x) = \begin{cases} 1, & P(y|x) \geq \tau \\ 0, & P(y|x) < \tau \end{cases}, \tau \in (0,1)$$

Метрики:

- $Accuracy = \frac{\text{correct classificaitons}}{\text{total classifications}} = \frac{TP+TN}{TP + TN + FP + FN}$

$$a(x) = \begin{cases} 1, & P(y|x) \geq \tau \\ 0, & P(y|x) < \tau \end{cases}, \tau \in (0,1)$$

Метрики:

- $Accuracy = \frac{\text{correct classificaitons}}{\text{total classifications}} = \frac{TP+TN}{TP + TN + FP + FN}$
- TP – true positive
- FP – false positive
- TN – true negative
- FN – false negative

$$a(x) = \begin{cases} 1, & P(y|x) \geq \tau \\ 0, & P(y|x) < \tau \end{cases}, \tau \in (0,1)$$

Метрики:

- $Accuracy = \frac{\text{correct classificaitons}}{\text{total classifications}} = \frac{TP+TN}{TP + TN + FP + FN}$
- TP – true positive (верно предсказанные «мошенники»)
- FP – false positive (ошибочно предсказанные «мошенники»)
- TN – true negative (верно предсказанные «негативы»)
- FN – false negative (ошибочно пропущенные «мошенники»)

Метрики

Метрики:

- $Accuracy = \frac{\text{correct classificaitons}}{\text{total classifications}} = \frac{TP+TN}{TP + TN + FP + FN}$

- $Precision = \frac{TP}{TP+FP}$ — «аккуратность» модели

- метрика важна, когда цена FP высока (к примеру, проверка невинного клиента)

- $Recall = \frac{TP}{TP+FN}$ — «полнота» модели

- метрика важна, когда цена FN высока (к примеру, пропуск мошенничества)

Метрики

Метрики:

- $Accuracy = \frac{\text{correct classificaitons}}{\text{total classifications}} = \frac{TP+TN}{TP + TN + FP + FN}$
- $Precision = \frac{TP}{TP+FP}$ — «аккуратность» модели
- $Recall = \frac{TP}{TP+FN}$ — «полнота» модели
- $"F1 - Score" = \frac{2*Precision*Recall}{Precision+Recall}$ — гармоничное среднее


Метрики

Метрики:


- $Accuracy = \frac{TP+TN}{TP+TN+FP+FN}$
- $Precision = \frac{TP}{TP+FP}$
- $Recall = \frac{TP}{TP+FN}$
- “F1 – Score”

		Real Label	
		Positive	Negative
Predicted Label	Positive	True Positive	False Positive
	Negative	False Negative	True Negative


Метрики



Метрики



Метрики




Метрики

ROC-AUC curve

ROC (receiver operator characteristics) иллюстрирует производительность классификации на всех порогах классификации τ .

AUC (Area Under the ROC Curve) — это мера, которая позволяет суммировать производительность модели одним числом, измеряя площадь под кривой ROC.



Мультиклассовая классификация линейных моделей

Эвристические методы:

- One vs All
- All vs All

Многоклассовая логистическая регрессия:

- Softmax

Мультиклассовая классификация линейных моделей

One vs All

- $Y = \{1, \dots, K\}$
- Обучим K бинарных классификаторов: $b_k(x) = \text{sign}(z)$
по выборкам $(x_i, 2[y_i = k] - 1)_i^N$ - т.е. $y_i = 1 \mid y = k$, иначе $y_i = 0$

Тогда положим:

$$a(x) = \arg \max_k (b_k(x))$$

- предпочтение отдается самому «уверенному алгоритму»

Мультиклассовая классификация линейных моделей

All vs All

- $Y = \{1, \dots, K\}$
- Обучим C_K^2 бинарных классификаторов: $b_{ij}(x), i, j = 1, \dots, K, i \neq j$
по подвыборкам $X_{ij} \subset X \Rightarrow b_{ij}: X \rightarrow Y\{i, j\}$

Тогда положим:

$$a(x) = \arg \max_k \left(\sum_i \sum_{j \neq i} (b_{ij}(x) = k) \right)$$

- предпочтение отдается «методом голосования».